Analyse automatique du narratif de corpus

Shami THIRION SEN

Lien vers le git du projet

Intro et rappel

Après avoir fait une première analyse du narratif du communisme au premier semestre, l'object du projet actuel est de mettre en pratique l'analyse automatique du narratif avec les outils TAL. Les approches

Le but étant une comparaison de corpus,

Script et procede

Afin de con

In [2]: # Bangla POS tagging

In [3]: def gen_words(texts):

bn pos = BengaliPOS()

from bnlp import BengaliCorpus as corpus stopwords = corpus.stopwords[:20] + ['\overline{a}' + '\overline{b}']

single_string = [' '.join(line) for line in texts]


La puissance de TAL!

Semantique textuelle

- · construction de corpus contrastif
 - corpus communiste vs. «non-communiste»
- · défi temps disponibilité des données
 - si le tp sem 1 visait le narratifs des temps communiste, (en hind sight) l'obtention du corpus est un défi non négligeable. À l'époque le Bengal est encore loin de la digitalisation des médias.

```
In [1]: import numpy as np
        import json
        import glob
        from pprint import pprint
        from collections import defaultdict
        import os, math
        from utils import * # import des fonctions depuis le fichier utils
        import gensim
        import gensim.corpora as corpora
        from gensim.corpora import Dictionary
        from gensim.utils import simple preprocess
        from gensim.models import CoherenceModel
        #visualisation
        import pyLDAvis
        import pyLDAvis.gensim
        # outils TAL en bengali
        import BnLemma as lm
        from bnlp import BengaliPOS
        import warnings
        warnings.filterwarnings("ignore", category=DeprecationWarning)
In [ ]:
```


```
data words = [gensim.utils.simple preprocess(text) for text in single string]
                return data words
 In [4]: ## BIGRAMMES ET TIGRAMMES
           def make bigrams(texts):
                # print(bigram[doc] for doc in texts)
                return ([bigram[doc] for doc in texts])
           def make_trigrams(texts):
                return([trigram[bigram[doc]] for doc in texts])
 In [5]: # on choisit le nombre de tokens (pour les 3 corpus)
           num tokens = 50000
           BanglaGanashakti
             · Lecture du corpus extrait et nettoyage
 In [6]: banglaGanashakti = "corpus/txtFiles/banglaGanashakti.txt"
           filtered ganashakti = read corpus(banglaGanashakti, num tokens)
           filtered_ganashakti = [list for list in filtered_ganashakti if len(list)>0] # old list_of_docs
 In [7]: # generation
           data_words = gen_words(filtered_ganashakti)
           print(data words[9][:200])
           # copy this
           bigram phrases = gensim.models.Phrases(filtered ganashakti, min count=5, threshold=50)
           trigram phrases = gensim.models.Phrases(bigram phrases[filtered ganashakti], threshold=50)
           bigram = gensim.models.phrases.Phraser(bigram phrases)
           trigram = gensim.models.phrases.Phraser(trigram_phrases)
           data_bigrams = make_bigrams(filtered_ganashakti)
           data_bigrams_trigrams = make_trigrams(data_bigrams)
           # data bigrams trigrams = make bigrams trigrams(filtered ganashakti)
          ['আরএসএস', 'অন', 'যবস', 'রহ্সন']
 In [8]: print(data bigrams trigrams[:10])
         [['বিধান', 'গণতন্ত্র'], ['বিধান', 'প্রস্তাব', 'তন্ত্র', 'শব্দ', 'সরকার', 'বেসরকারি', 'হাত', 'পরিষ্কার'], ['বিয়োজন', 'চেয়ে', 'বিজেপি', 'সাংসদ', 'সরকার', 'মুখ', 'এমন', 'দেশ'], ['সংসদ', 'বেসরকারি', 'বিলটি', 'সংবাদ', 'ক্ষেত্র', 'দেশ', 'পুঁজি', 'প্রবেশ্'], ['মাধ্যম', 'প্রতিবেদন', 'স্বনির্ভরতায়', 'প্রম', 'চহ্নু', 'পড়া'], ['লেখা', 'বিধানু', 'প্রাস্তাবনায়', 'প্রম', 'মুখ', 'বিচার',
         'সুপ্রিমকোট'], ['নিরপেক্ষ', 'শব্দ', 'সংযোজনা', 'দেশ', 'বিচার', 'যুক্তি', 'প্রমাণ', 'পরিবর্তন'], ['মূর্তি', 'খর', 'মন্তব্য', 'দেশ',
'একাত্তর', 'বিশ্বাস', 'ভিত্তি', 'অযোধ্যা'], ['কাশীর', 'লাদাখ', 'হাইকোট', 'বিচার', 'পঙ্কজ', 'মামলা', 'রায়', 'দান', 'অ
সুবিধে'], ['থাল', 'আরএসএস', 'অনুষ্ঠান', 'হাজির', 'গোটা', 'ব্যবস্হা', 'প্রহসন']]
 In [9]: ### TF-IDF
           id2word = Dictionary(data bigrams trigrams)
           corpus = [id2word.doc2bow(text) for text in filtered ganashakti]
           word = id2word[[9][:1][0]]
           print (word)
          এমন
In [10]: corpus=get_corpus(corpus,id2word)
           # corpus[:10]
           # print(corpus)
In [11]: lda model = gensim.models.ldamodel.LdaModel(corpus=corpus,
                                                                 id2word=id2word,
                                                                 num topics=20,
                                                                 random state=100,
                                                                 update every=1,
                                                                 chunksize=200,
                                                                 passes=10,
                                                                 alpha="auto")
In [12]: pyLDAvis.enable_notebook()
           vis = pyLDAvis.gensim.prepare(lda model, corpus, id2word, mds="mmds", R=30)
```



```
'কাগজ': 1.7034556832544927.
                  'ঘটনা': 1.7034556832544927,
                  'দেশ': 2.822366552123779,
                  'বছর': 3.981652821276082,
                  'বিরোধ': 1.7034556832544927,
                  'মুখ': 1.3058448579813575,
                  'রাজ্য': 1.7034556832544927,
                  'সংস্থা': 2.4176201267623734,
                  'সভা': 1.4214206099086821}
                Token les moins spécifiques:
                { 'আবেদন ': -1.4734260601920461,
                  'তৈরি': -0.6995223437085923,
                  'প্রশাসক': -1.1313767185499328,
                  'ভারত': -0.5644679352351545,
                  'ভ্যাকসিন': -1.1313767185499328.
                  'মঙ্গলেবার': -0.9112545540878407,
                  'মন': -0.5976209869719409,
                  'মানুষ': -1.846381145742381,
                  'সরকার': -0.7250544362478527,
                  'হাইকোর্ট': -0.6995223437085923}
                  Bartamanpatrika
In [17]: bartamanpatrika = "corpus/txtFiles/bartamanpatrika.txt"
                  filtered bartamanpatrika = read corpus(bartamanpatrika, num tokens)
                  filtered_bartamanpatrika = [list for list in filtered_bartamanpatrika if len(list)>0]
In [18]: # generation
                  data_words = gen_words(filtered_bartamanpatrika)
                  # print(data words[9][:200])
                  bigram_phrases = gensim.models.Phrases(filtered_bartamanpatrika, min_count=5, threshold=50)
                  trigram phrases = gensim.models.Phrases(bigram phrases[filtered bartamanpatrika], threshold=50)
                  bigram = gensim.models.phrases.Phraser(bigram_phrases)
                  trigram = gensim.models.phrases.Phraser(trigram phrases)
                  data_bigrams = make_bigrams(filtered_bartamanpatrika)
                  data_bigrams_trigrams = make_trigrams(data_bigrams)
In [19]: print(data_bigrams_trigrams[:10])
                [['শত', 'নেতৃত্ব', 'ক্রিকেট', 'কনেট্রাল', 'বোর্ড', 'প্রস্তাব', 'গ্রহণ', 'শত', 'টেস্ট', 'অধিনায়ক', 'ম্যাচ', 'মাইলস্টোন', 'ম্যাচ',
               াত , তাত্ব , ভিজেও , কটোলা , আত , এডাব , এইন , নত , তেন্ট , আবনারক , বাচি , বাহলতোলি , বাচি , বাহলতালি , বাহলতা
                'প্লেঅফে'], ['আইএসএলে', 'সোমবার', 'জাম', 'হায়', 'এফ', 'ম্যাচ']]
In [20]: ### TF-IDF
                  id2word = Dictionary(data_bigrams_trigrams)
                  corpus = [id2word.doc2bow(text) for text in filtered_bartamanpatrika]
                  word = id2word[[9][:1][0]]
                  print (word)
                প্রস্তাব
In [21]: corpus=get corpus(corpus,id2word)
In [22]: lda model = gensim.models.ldamodel.LdaModel(corpus=corpus,
                                                                                                         id2word=id2word,
                                                                                                         num topics=30,
                                                                                                          random state=100,
                                                                                                         update every=1,
                                                                                                         chunksize=100.
```

Token les plus spécifiques:

{ 'অভিযোগ': 1.7034556832544927,



```
{ 'অগ্রসর': 2.213898518699129,
            'অর্থকডি': 1.1917822053964344.
            'আনন্দ': 1.194358070023163,
            'উপার্জন': 2.4791153722921853,
            'কাজ': 2.391591541360233,
            'পদ': 1.4933962140349704,
            'বিদ্যা': 2.175673473348266,
            'ব্যবসায়': 4.993389359623521,
            'যোগ': 2.640928523468916,
            'সুখ': 1.194358070023163}
          Token les moins spécifiques:
          { 'কর্মী ': -1.2203845358262584,
            'কলকাতা': -2.725720195793848,
            'গুহে': -1.473846371473666,
            'টাকা': -1.282643850251739,
            'প্রেম': -2.225818409875582.
            'বুধবার': -2.263926350293847,
            'ম্মতা': -1.2203845358262584,
            'মানুষ': -1.473846371473666,
            'রাজ্জাক': -2.5345546860291215,
            'রাজ্য': -2.263926350293847}
            Anandabazar
              • corpus qui avec 1000 tokens pointe vers cricket et le sujet de sport
              • Alors qu'avec 10000 nous obtenons plus de généralité
In [27]: anandabazar = "corpus/txtFiles/anandabazar.txt"
            filtered anandabazar = read corpus(anandabazar, num tokens)
            filtered anandabazar = [list for list in filtered anandabazar if len(list)>0]
In [28]: # generation
            data words = gen words(filtered anandabazar)
            # print(data words[9][:200])
            # copy_this
            bigram_phrases = gensim.models.Phrases(filtered_anandabazar, min_count=5, threshold=50)
            trigram phrases = gensim.models.Phrases(bigram phrases[filtered anandabazar], threshold=50)
            bigram = gensim.models.phrases.Phraser(bigram_phrases)
            trigram = gensim.models.phrases.Phraser(trigram phrases)
            data bigrams = make bigrams(filtered anandabazar)
            data_bigrams_trigrams = make_trigrams(data_bigrams)
In [29]: print(data bigrams trigrams[:10])
          [['১৫টা', 'লোক', 'ঘিরে'], ['ষষ্ঠী', 'সগুম', 'তুলনা', 'রবিবার', 'গা', 'রাস্তা', 'গা', 'উত্তর', 'দক্ষিণ', 'নিয়ন্ত্রণ', 'বড়', 'পুজোগুলোয়', 'চোখ', 'পড়া'], ['রাজ্য', 'বিজড়িত', 'ভাঙা', 'দশ', 'রাম', 'সুনীল', 'বনসাই', 'দল', 'নেতৃত্ব', 'পর্যবেক্ষণ', 'মঙ্গল', 'পরিকল্পনা', 'পালন', 'দায়িত্ব'], ['কোটি', 'গুটখায়', 'রঙ', 'শহর'], ['শীর্ষ', 'আদালত', 'মানুষ', 'আস্থা', 'বজায়',
          'দায়িত্ব', 'কার'], ['সাল', 'বিধান', 'নির্বচন', 'শুরু', 'বিজড়িত', 'সাল', 'বিতর্ক', 'আরাধন', 'সুকান্ত', 'বারেক', 'পুজোতেই', 
'সুলতান'], ['কংগ্রেস', 'প্রস্তাব', 'বাদ', 'শুরু', 'জোট'], ['ডিএ', 'মামলা', 'ধান্ধা', 'খেল', 'রাজ্য', 'সরকার'], ['সোমবার',
'রাত', '৮টা', 'মৃত্যু', 'মৃত', 'পরিবার', 'দেহ', 'নিতে', 'স্বীকার'], ['বারেক', 'চেষ্টায়', 'দিন', 'যোগ', 'সরকার', 'হা', 'অ
          নুমোদন', 'রাহুলপ্রিয়ঙ্কা']]
In [30]: ### TF-IDF
            id2word = Dictionary(data_bigrams_trigrams)
            corpus = [id2word.doc2bow(text) for text in filtered_anandabazar]
            word = id2word[[9][:1][0]]
            print (word)
            corpus=get corpus(corpus,id2word)
            # corpus[:10]
          পডা
In [31]: | lda_model = gensim.models.ldamodel.LdaModel(corpus=corpus,
                                                                    id2word=id2word.
```

Token les plus spécifiques:

```
num_topics=20,
                                                          random_state=100,
                                                          update_every=1,
                                                          chunksize=200,
                                                          passes=10,
                                                          alpha="auto")
In [32]: pyLDAvis.enable_notebook()
          vis = pyLDAvis.gensim.prepare(lda_model, corpus, id2word, mds="mmds", R=30)
          vis
Out[32]: Selected Topic: 0
                                  Previous Topic | Next Topic | Clear Topic |
                                                                                                      Slide to adjust relevance metri (2)
                                                                                                                 \lambda = 1
                        Intertopic Distance Map (via multidimensional scaling)
                                                                                                                              ٦
                                                                                                                           10
                                                     PC2
                                                                                                   দেশ
                                                                                                 রাজ্জাক
                                                                                                   বছর
                                                                                                  সরকার
                                                                                                  ভারত
                                                     15
                                                                                                  পুলিশ
                                                                                                   দিন
                                                                                                অভিযোগ
                                                                  16
                                                                                 12
                                                                                                 বিজেপি
                                                                                                   ঘণ্টা
                                            14
                                                                                                   দাবি
                 2
                                                                                                   হাত
                                                                      19
                                                                                                বিজড়িত
             PC1
                                                         20
                                                                                                    মুখ
                                                                                                   সাল
                                       13
                                                                                     11
                                                                     18
                                                                                                  মামলা
                                                                                                  উত্তর
                                                                                                কলকাতা
                                                      17
                                                                                                   ছবি
                                                                                                  কারন
                                                                                                   ভোট
                                                                                 10
                    1
                                                                                                  দফতর
                                                                                                  মমতা
                                                                                                    সূত্ৰ
                                                                                                রাজনীতি
                                                                                                সিবিআই
In [33]: pyLDAvis.save_html(vis, 'topic_modeling_anandabazar.html')
          Calcul de spécificité
In [34]: max_specificity, min_specificity = get_higest_lowest_specificity(filtered_anandabazar, 10)
In [35]: print('Token les plus spécifiques:\n')
          pprint(max_specificity)
          print('\nToken les moins spécifiques:\n')
          pprint(min_specificity)
```

Token les plus spécifiques:

```
{'কলকাতা': 1.5778801614714248,
 'ថា': 1.4970557220813931,
 'দিন': 1.4548077207324708,
 'फिल्लि': 1.4970557220813931,
 'নেতা': 1.5965450463804507,
 'পশ্চিম': 1.4970557220813931,
 'প্ৰাক্তন': 1.4970557220813931,
 'ভোট': 3.258295599096833,
 'ম্যাচ': 1.4970557220813931,
 'হাসপাতাল': 1.8719243107077876}
Token les moins spécifiques:
{ 'ঘণ্টা ': -1.9391756661987243,
 'ছবি': -1.211895433809877,
 'টাকা': -1.3875543891087163,
 'দেশ': -1.1934798488373901,
 'ধার': -1.2700287066563456,
 'পাকিস্তান': -1.074699978134664,
 'বিজেপি': -1.5146775696522612,
 'বৃহস্পতিবার': -1.2700287066563456,
 'সোমবার': -1.2700287066563456,
 'হাত': -1.4695469731929143}
```

Conclusion

Après uen .. nous pouvons constater que...

P.S.

Ce rapport se trouve en version jupyter notebook dans le dossier scripts . Normalement, l'installation des bibliothèques mentionnées dans requirement.txt permettent d'executer le notebook afin de reproduire les résultats. (Il se peut que quelques bibliothèques inutiles soient listés dans requirement.txt).

In []: